

第七章

参数估计

统计推断
DE
基本问题

参数估计问题

点估计

区间估计

假设检验问题

什么是参数估计？

参数是刻画总体某方面的概率特性的数量.

当这个数量是未知的时候，从总体抽出一个样本，用某种方法对这个未知参数进行估计就是参数估计.

例如， $X \sim N(\mu, \sigma^2)$,

若 μ, σ^2 未知，通过构造样本的函数，给出它们的估计值或取值范围就是参数估计的内容.

点估计

区间估计

参数估计的类型

点估计 —— 估计未知参数的值

区间估计—— 估计未知参数的取值范围，
使得这个范围包含未知参数
真值的概率为给定的值。

§ 7.1 点估计及评选标准

一、点估计的思想方法

设总体 X 的分布函数的形式已知，但它含有一个或多个未知参数： $\theta_1, \theta_2, \dots, \theta_k$

设 X_1, X_2, \dots, X_n 为总体的一个样本

构造 k 个统计量：

$$\theta_1(X_1, X_2, \dots, X_n)$$

$$\theta_2(X_1, X_2, \dots, X_n)$$

.....

$$\theta_k(X_1, X_2, \dots, X_n)$$

随机变量

当测得一组样本值 (x_1, x_2, \dots, x_n) 时，代入上述统计量，即可得到 k 个数：

$$\left. \begin{array}{l} \hat{\theta}_1(x_1, x_2, \dots, x_n) \\ \hat{\theta}_2(x_1, x_2, \dots, x_n) \\ \dots\dots\dots \\ \hat{\theta}_k(x_1, x_2, \dots, x_n) \end{array} \right\} \boxed{\text{数值}}$$

称数 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 为未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的估计值

对应的统计量为未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的估计量

问题 如何构造统计量？

如何评价估计量的好坏？

二、矩估计法

方法

用样本的 k 阶矩作为总体的 k 阶矩的估计量, 建立含有待估计参数的方程, 从而可解出待估计参数.

一般地, 不论总体服从什么分布, 总体期望 μ 与方差 σ^2 存在, 则它们的矩估计量分别为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$

事实上，按矩法原理，令

$$\left\{ \begin{array}{l} \mu_1 = \mu = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \\ \mu_2 = E(X^2) = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{array} \right.$$

$$\longrightarrow \left\{ \begin{array}{l} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = E(\hat{X}^2) - E^2(\hat{X}) = A_2 - \hat{\mu}^2 \end{array} \right.$$

$$= \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$

设待估计的参数为 $\theta_1, \theta_2, \dots, \theta_k$

设总体的 r 阶矩存在，记为

$$E(X^r) = \mu_r(\theta_1, \theta_2, \dots, \theta_k)$$

设 X_1, X_2, \dots, X_n 为一样本，样本的 r 阶矩为

$$A_r = \frac{1}{n} \sum_{i=1}^n X_i^r$$

$$\text{令 } \mu_r(\theta_1, \theta_2, \dots, \theta_k) = A_r = \frac{1}{n} \sum_{i=1}^n X_i^r \quad r = 1, 2, \dots, k$$

—— 含未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的方程组

解方程组，得 k 个统计量：

$$\hat{\theta}_1(X_1, X_2, \dots, X_n)$$

$$\hat{\theta}_2(X_1, X_2, \dots, X_n)$$

.....

$$\hat{\theta}_k(X_1, X_2, \dots, X_n)$$

——未知参数 $\theta_1, \theta_2, \dots, \theta_k$
的矩估计量

代入一组样本值得 k 个数：

$$\hat{\theta}_1 = \hat{\theta}_1(x_1, x_2, \dots, x_n)$$

$$\hat{\theta}_2 = \hat{\theta}_2(x_1, x_2, \dots, x_n)$$

.....

$$\hat{\theta}_k = \hat{\theta}_k(x_1, x_2, \dots, x_n)$$

——未知参数 $\theta_1, \theta_2, \dots, \theta_k$
的矩估计值

例1 设总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 为总体的样本, 求 μ, σ^2 的矩法估计量。

解 $\hat{\mu}_{\text{矩}} = \bar{X}$

$$\hat{\sigma}_{\text{矩}}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

例2 设总体 $X \sim E(\lambda)$, X_1, X_2, \dots, X_n 为总体的样本, 求 λ 的矩法估计量。

解 $\mu_1 = E(X) = \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$ 令 $\bar{X} = \frac{1}{\lambda}$

故 $\hat{\lambda}_{\text{矩}} = \frac{1}{\bar{X}}$

例3 设总体 X 的概率密度为

$$f(x) = \begin{cases} (\alpha + 1)x^\alpha, & 0 < x < 1 \\ 0, & \text{其它} \end{cases}$$

其中 $\alpha > -1$
是未知参数,

X_1, X_2, \dots, X_n 是取自 X 的样本, 求参数 α 的矩估计.

解 $\mu_1 = E(X) = \int_0^1 x(\alpha + 1)x^\alpha dx$

数学期望
是一阶
原点矩

$$= (\alpha + 1) \int_0^1 x^{\alpha+1} dx = \frac{\alpha + 1}{\alpha + 2}$$

由矩法,

$$\bar{X} = \frac{\alpha + 1}{\alpha + 2}$$

总体矩

样本矩

从中解得 $\hat{\alpha} = \frac{2\bar{X} - 1}{1 - \bar{X}}$, 即为 α 的矩估计.

例4 设总体 $X \sim U(a, b)$, a, b 未知, 求 a, b 的矩法估计量.

解 由于 $E(X) = \frac{a+b}{2}$, $D(X) = \frac{(b-a)^2}{12}$

$$E(X^2) = D(X) + E^2(X) = \frac{(b-a)^2}{12} + \left(\frac{a+b}{2}\right)^2$$

$$\text{令} \begin{cases} \frac{\hat{a} + \hat{b}}{2} = \bar{X} \\ \frac{(\hat{b} - \hat{a})^2}{12} + \left(\frac{\hat{a} + \hat{b}}{2}\right)^2 = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

解得

$$\hat{a}_{\text{矩}} = \bar{X} - \sqrt{3(A_2 - \bar{X}^2)}$$

$$= \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{b}_{\text{矩}} = \bar{X} + \sqrt{3(A_2 - \bar{X}^2)}$$

$$= \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

三、极大似然估计法

思想方法：一次试验就出现的事件有较大的概率

例如：有两个外形相同的箱子，都装有100个球

一箱 99个白球， 1个红球

一箱 1个白球， 99个红球

现从两箱中任取一箱，并从箱中任取一球，
结果所取得的球是白球。

问 所取的球来自哪一箱？

答 第一箱。

例5 设总体 X 服从0-1分布, 且 $P\{X=1\}=p$,
用极大似然法求 p 的估计值。

解 X 的概率分布可以写成

$$P\{X=x\}=p^x(1-p)^{1-x}, \quad x=0,1$$

设 X_1, X_2, \dots, X_n 为总体 X 的样本,


设 x_1, x_2, \dots, x_n 为总体 X 的样本值,

则 $P\{X_1=x_1, X_2=x_2, \dots, X_n=x_n\}$

$$= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} = L(p)$$

$$x_i = 0, 1, i = 1, 2, \dots, n$$

对于不同的 p , $L(p)$ 不同, 见右下图



现经过一次试验, 事件

$$\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$$

发生了, 则 p 的取值应使这个事件发生的概率最大。

在容许的范围内选择 p , 使 $L(p)$ 最大

注意到, $\ln L(p)$ 是 L 的单调增函数, 故 若某个 p 使 $\ln L(p)$ 最大, 则这个 p 必使 $L(p)$ 最大。

$$\frac{d \ln L}{dp} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} \stackrel{\text{令}}{=} 0 \Rightarrow \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

$$\left(\frac{d^2 \ln L}{dp^2} = -\frac{\sum_{i=1}^n x_i}{p^2} - \frac{n - \sum_{i=1}^n x_i}{(1-p)^2} < 0 \right)$$

所以 $\hat{p} = \bar{x}$ 为所求 p 的估计值.

一般地，设 X 为离散型随机变量，其分布律为

$$P\{X = x\} = f(x, \theta), \quad x = u_1, u_2, \dots, \theta \in \Theta$$

X_1, X_2, \dots, X_n 为总体 X 的样本，

x_1, x_2, \dots, x_n 为总体 X 的样本值，

则 X_1, X_2, \dots, X_n 的分布律为

$$\begin{aligned} &P\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} \\ &= f(x_1, \theta) f(x_2, \theta) \cdots f(x_n, \theta) \end{aligned}$$

记为

$$= L(x_1, x_2, \dots, x_n, \theta) \stackrel{\text{或}}{=} L(\theta) \quad x_i = u_1, u_2, \dots,$$

$$i = 1, 2, \dots, n, \theta \in \Theta$$

称 $L(\theta)$ 为样本的似然函数

当给定一组样本值时, $L(\theta)$ 就是参数 θ 的函数, 极大似然估计法的思想就是:

选择适当的 $\theta = \hat{\theta}$, 使 $L(\theta)$ 取最大值, 即

$$\begin{aligned} & L(x_1, x_2, \dots, x_n, \hat{\theta}) \\ &= \max_{\theta \in \Theta} \{ f(x_1, \theta) f(x_2, \theta) \cdots f(x_n, \theta) \} \end{aligned}$$

则称这样得到的 $\hat{\theta}$

$$\hat{\theta} = g(x_1, x_2, \dots, x_n)$$

为参数 θ 的极大似然估计值 简记 $\hat{\theta}_{mle}$

称统计量

$$\hat{\theta} = g(X_1, X_2, \dots, X_n)$$

为参数 θ 的极大似然估计量 简记 $\hat{\theta}_{MLE}$

注1 若随机变量 X 连续, 取 $f(x_i, \theta)$ 为 X_i 的密度函数

似然函数为
$$L(\theta) = \prod_{i=1}^n f(x_i, \theta)$$

注2 未知参数个数可以不止一个, 如 $\theta_1, \theta_2, \dots, \theta_k$

设 X 的概率密度(或分布律)为 $f(x, \theta_1, \theta_2, \dots, \theta_k)$

则定义似然函数为

$$\begin{aligned} &L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) \\ &= L(\theta_1, \theta_2, \dots, \theta_k) = \prod_{i=1}^n f(x_i, \theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

$$-\infty < x_i < +\infty, i = 1, 2, \dots, n \quad (\theta_1, \theta_2, \dots, \theta_k) \in \Theta$$

若 $L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$ 关于 $\theta_1, \theta_2, \dots, \theta_k$ 可微, 则称

$$\frac{\partial}{\partial \theta_r} L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = 0 \quad r = 1, 2, \dots, k$$

为似然方程组

若对于某组给定的样本值 x_1, x_2, \dots, x_n , 参数 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 使得似然函数取得最大值, 即

$$\begin{aligned} & L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) \\ &= \max_{(\theta_1, \theta_2, \dots, \theta_k) \in \Theta} \{L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)\} \end{aligned}$$

则称 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 为 $\theta_1, \theta_2, \dots, \theta_k$ 的极大似然估计值

显然 ,

$$\hat{\theta}_r = g(x_1, x_2, \dots, x_n) \quad r = 1, 2, \dots, k$$

称统计量

$$\hat{\theta}_r = g(X_1, X_2, \dots, X_n) \quad r = 1, 2, \dots, k$$

为 $\theta_1, \theta_2, \dots, \theta_k$ 的极大似然估计量

例6 设总体 $X \sim N(\mu, \sigma^2)$, x_1, x_2, \dots, x_n 是 X 的一组样本值, 求 μ, σ^2 的极大似然估计.

解 $L(x_1, x_2, \dots, x_n; \mu, \sigma^2)$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \frac{1}{(2\pi)^{\frac{n}{2}} (\sigma^2)^{\frac{n}{2}}} e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$\ln L = -\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} - \frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2)$$

似然
方程
组为

$$\left\{ \begin{array}{l} \left(\frac{\partial}{\partial \mu} \ln L \right) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \left(\frac{\partial}{\partial (\sigma^2)} \ln L \right) = \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2(\sigma^2)} = 0 \end{array} \right.$$

$$\longrightarrow \left\{ \begin{array}{l} \hat{\mu}_{mle} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \hat{\sigma}_{mle}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{array} \right.$$

μ, σ^2 的极大似然估计量分别为

$$\frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \qquad \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$

求未知参数的极大似然估计值(量)的方法

1) 写出似然函数 L

2) 求出 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$, 使得

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)$$

$$= \max_{(\theta_1, \theta_2, \dots, \theta_k) \in \Theta} \{L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)\}$$

若 L 是 $\theta_1, \theta_2, \dots, \theta_k$ 的可微函数, 解似然方程组

$$\frac{\partial}{\partial \theta_r} \ln L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = 0$$

$$r = 1, 2, \dots, k$$

可求得未知参数的极大似然估计值 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$
然后, 再求得极大似然估计量.

若 L 不是 $\theta_1, \theta_2, \dots, \theta_k$ 的可微函数, 需用其它方法求极大似然估计值. 请看下例:

例7 设 $X \sim U(a, b)$, x_1, x_2, \dots, x_n 是 X 的一个样本, 求 a, b 的极大似然估计值与极大似然估计量.

解 X 的密度函数为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其它} \end{cases}$$

似然函数为

$$L(x_1, x_2, \dots, x_n; a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a < x_i < b, \\ 0, & i = 1, 2, \dots, n \\ & \text{其它} \end{cases}$$

似然函数只有当 $a < x_i < b, i = 1, 2, \dots, n$ 时才能获得最大值, 且 a 越大, b 越小, L 越大.

令 $x_{\min} = \min \{x_1, x_2, \dots, x_n\}$
 $x_{\max} = \max \{x_1, x_2, \dots, x_n\}$

取 $\hat{a} = x_{\min}, \hat{b} = x_{\max}$

则对满足 $a \leq x_{\min} \leq x_{\max} \leq b$ 的一切 $a < b$, 都有

$$\frac{1}{(b-a)^n} \leq \frac{1}{(x_{\max} - x_{\min})^n}$$

故 $\hat{a} = x_{\min}, \hat{b} = x_{\max}$

是 a, b 的极大似然估计值.

$$X_{\min} = \min\{X_1, X_2, \dots, X_n\}$$

$$X_{\max} = \max\{X_1, X_2, \dots, X_n\}$$

分别是 a, b 的极大似然估计量.

四、点估计的评价标准

对于同一个未知参数，不同的方法得到的估计量可能不同，于是提出问题

- △ 应该选用哪一种估计量？
- △ 用什么标准来评价一个估计量的好坏？

常用 标准	{	(1) 一致性
		(2) 无偏性
		(3) 有效性

1、一致性

定义 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是总体参数 θ 的估计量. 若对于任意的 $\theta \in \Theta$, 当 $n \rightarrow \infty$ 时, $\hat{\theta}$ 依概率收敛于 θ , 即 $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| \geq \varepsilon\} = 0$$

则称 $\hat{\theta}$ 是总体参数 θ 的一致(或相合)估计量.

一致性估计量仅在样本容量 n 足够大时,才显示其优越性.

关于一致性的两个常用结论

1. 样本 k 阶矩是总体 k 阶矩的一致性估计量. } 由大数定律证明
2. 设 $\hat{\theta}$ 是 θ 的无偏估计量, 且 $\lim_{n \rightarrow \infty} D(\hat{\theta}) = 0$, 则 $\hat{\theta}$ 是 θ 的一致估计量. } 用切贝雪夫不等式证明

矩法得到的估计量一般为一致估计量

在一定条件下, 极大似然估计具有一致性

2、无偏性

定义 设 (X_1, X_2, \dots, X_n) 是总体 X 的样本
 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是总体参数 θ 的估计量
 $E(\hat{\theta})$ 存在, 且对于任意 $\theta \in$ 都有
$$E(\hat{\theta}) = \theta$$

则 $\hat{\theta}$ 是 θ 的无偏估计量.

例8 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ 存在

(X_1, X_2, \dots, X_n) 是总体 X 的样本,

证明: 不论 X 服从什么分布, $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
是 μ_k 的无偏估计量.

证 由于 $E(X_i^k) = \mu_k \quad i = 1, 2, \dots, n$ 因而

$$\begin{aligned} E(A_k) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) \\ &= \frac{1}{n} \cdot n \cdot \mu_k = \mu_k \end{aligned}$$

特别地,

样本均值 \bar{X} 是总体期望 $E(X)$ 的无偏估计量

样本二阶原点矩 $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$ 是总体二阶

原点矩 $\mu_2 = E(X^2)$ 的无偏估计量

例9 设总体 X 的期望 $E(X)$ 与方差 $D(X)$ 存在, (X_1, X_2, \dots, X_n) 是 X 的一个样本, $n > 1$. 证明

(1) $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 不是 $D(X)$ 的无偏估计量;

(2) $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $D(X)$ 的无偏估计量.

证 前已证 $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$

$$E(X_i) = E(X) = \mu, \quad D(X_i) = D(X) = \sigma^2$$

$$E(\bar{X}) = E(X) = \mu, \quad D(\bar{X}) = \frac{\sigma^2}{n}$$

因而
$$E\left(\frac{1}{n}\sum_{i=1}^n(X_i - \bar{X})^2\right) = \frac{1}{n}\sum_{i=1}^n E(X_i^2) - E(\bar{X}^2)$$
$$= (\sigma^2 + \mu^2) - \left(\frac{\sigma^2}{n} + \mu^2\right)$$
$$= \frac{n-1}{n}\sigma^2 \neq \sigma^2$$

故
$$E\left(\frac{1}{n-1}\sum_{i=1}^n(X_i - \bar{X})^2\right) = \sigma^2 \quad \text{证毕.}$$

例10 设 (X_1, X_2, \dots, X_m) 是总体 X 的一个样本，
 $X \sim B(n, p)$ $n > 1$ ，求 p^2 的无偏估计量。

解 由于样本矩是总体矩的无偏估计量以及数学期望的线性性质，只要将未知参数表示成总体矩的线性函数，然后用样本矩作为总体矩的估计量，这样得到的未知参数的估计量即为无偏估计量。

$$\text{令 } \bar{X} = E(X) = np$$

$$\frac{1}{m} \sum_{i=1}^m X_i^2 = E(X^2) = (np)^2 + np(1-p)$$

故 $(n^2 - n)p^2 = \frac{1}{m} \sum_{i=1}^m X_i^2 - \bar{X}$

因此, p^2 的无偏估计量为

$$\begin{aligned} \hat{p}^2 &= \frac{1}{n^2 - n} \left(\frac{1}{m} \sum_{i=1}^m X_i^2 - \bar{X} \right) \\ &= \frac{\frac{1}{m} \sum_{i=1}^m X_i(X_i - 1)}{n(n - 1)} \end{aligned}$$

例12 设总体 X 的密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & x > 0, \\ 0 & x \leq 0 \end{cases} \quad \theta > 0 \text{ 为常数}$$

(X_1, X_2, \dots, X_n) 为 X 的一个样本

证明 \bar{X} 与 $n \min\{X_1, X_2, \dots, X_n\}$ 都是 θ 的无偏
估计量

证 $X \sim E\left(\frac{1}{\theta}\right) \quad E(X) = \theta$

故 $E(\bar{X}) = E(X) = \theta$

\bar{X} 是 θ 的无偏估计量.

$$\text{令} \quad Z = \min\{X_1, X_2, \dots, X_n\}$$

$$\begin{aligned} F_Z(z) &= 1 - P(X_1 > z, X_2 > z, \dots, X_n > z) \\ &= 1 - P(X_1 > z)P(X_2 > z) \cdots P(X_n > z) \end{aligned}$$

$$\begin{aligned} &= 1 - \prod_{i=1}^n (1 - P(X_i \leq z)) = \begin{cases} 0 & z < 0 \\ 1 - e^{-\frac{nz}{\theta}} & z \geq 0 \end{cases} \\ f_Z(z) &= \begin{cases} 0 & z < 0 \\ \frac{n}{\theta} e^{-\frac{nz}{\theta}} & z \geq 0 \end{cases} \end{aligned}$$

$$\text{即} \quad Z \sim E\left(\frac{n}{\theta}\right) \quad E(Z) = \frac{\theta}{n} \quad E(nZ) = \theta$$

故 nZ 是 θ 的无偏估计量.

3、有效性

定义 设 $\hat{\theta}_1 = \theta_1(X_1, X_2, \dots, X_n)$

$$\hat{\theta}_2 = \theta_2(X_1, X_2, \dots, X_n)$$

都是总体参数 θ 的无偏估计量, 且

$$D(\hat{\theta}_1) < D(\hat{\theta}_2)$$

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效.

例13 设 X_1, X_2, \dots, X_n 为 X 的一个样本, 密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & x > 0, \\ 0 & x \leq 0 \end{cases} \quad \theta > 0 \text{ 为常数}$$

由前面例4 可知, \bar{X} 与 $n \min\{X_1, X_2, \dots, X_n\}$ 都是 θ 的无偏估计量, 问哪个估计量更有效?

解
$$D(\bar{X}) = \frac{\theta^2}{n} \quad D(n \min\{X_1, X_2, \dots, X_n\}) = \theta^2$$

所以, \bar{X} 比 $n \min\{X_1, X_2, \dots, X_n\}$ 更有效.

例14 设总体期望为 $E(X)=\mu$, 方差 $D(X)=\sigma^2$

(X_1, X_2, \dots, X_n) 为总体 X 的一个样本

(1) 设常数 $c_i \neq \frac{1}{n} \quad i=1, 2, \dots, n. \quad \sum_{i=1}^n c_i = 1.$

证明 $\hat{\mu}_1 = \sum_{i=1}^n c_i X_i$ 是 μ 的无偏估计量

(2) 证明 $\hat{\mu} = \bar{X}$ 比 $\hat{\mu}_1 = \sum_{i=1}^n c_i X_i$ 更有效

证: (1) $E(\hat{\mu}_1) = \sum_{i=1}^n c_i E(X_i) = \sum_{i=1}^n c_i \mu = \mu$

$$(2) \quad D(\hat{\mu}_1) = \sum_{i=1}^n c_i^2 D(X_i) = \sigma^2 \sum_{i=1}^n c_i^2$$

$$\begin{aligned} \text{而} \quad 1 &= \left(\sum_{i=1}^n c_i \right)^2 = \sum_{i=1}^n c_i^2 + 2 \sum_{1 \leq i < j \leq n} c_i c_j \\ &< \sum_{i=1}^n c_i^2 + \sum_{1 \leq i < j \leq n} (c_i^2 + c_j^2) = n \sum_{i=1}^n c_i^2 \end{aligned}$$

$$\Rightarrow \sum_{i=1}^n c_i^2 > \frac{1}{n} \Rightarrow D(\hat{\mu}) = \frac{1}{n} \sigma^2 < D(\hat{\mu}_1)$$

结论

算术均值比加权均值更有效.

例如 $X \sim N(\mu, \sigma^2)$, (X_1, X_2) 是一样本.

$$\left. \begin{aligned} \hat{\mu}_1 &= \frac{2}{3}X_1 + \frac{1}{3}X_2 \\ \hat{\mu}_2 &= \frac{1}{4}X_1 + \frac{3}{4}X_2 \\ \hat{\mu}_3 &= \frac{1}{2}X_1 + \frac{1}{2}X_2 \end{aligned} \right\} \text{都是 } \mu \text{ 的无偏估计量}$$

由例14(2) 知 $\hat{\mu}_3$ 最有效.

罗—克拉美 (*Rao – Cramer*) 不等式

若 $\hat{\theta}$ 是参数 θ 的无偏估计量, 则

$$D(\hat{\theta}) \geq \frac{1}{nE\left[\frac{\partial}{\partial\theta} \ln p(X, \theta)\right]^2} = D_0(\theta)$$

其中 $p(x, \theta)$ 是总体 X 的概率分布或密度函数

数 (θ)
称为方差的下界; 称 $\hat{\theta}$ 为达到方差下界的无偏估计量, 此时称 $\hat{\theta}$ 为最有效的估计量, 简称有效估计量.

例8 设总体 X 的密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & x > 0, \\ 0 & x \leq 0 \end{cases} \quad \theta > 0 \text{ 为常数}$$

(x_1, x_2, \dots, x_n) 为 X 的一个样本值.

求 θ 的极大似然估计量, 并判断它是否是达到方差下界的无偏估计量.

解 由似然函数

$$L(\theta) = \frac{1}{\theta^n} e^{-\frac{\sum_{i=1}^n x_i}{\theta}} \longrightarrow \ln L(\theta) = -n \ln \theta - \frac{\sum_{i=1}^n x_i}{\theta}$$

$$\frac{d}{d\theta} \ln L(\theta) = -\frac{n}{\theta} + \frac{\sum_{i=1}^n x_i}{\theta^2} \stackrel{\text{令}}{=} 0$$

$$\longrightarrow \hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

θ 的极大似然估计量为 $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$


它是 θ 的无偏估计量.

$$D(\hat{\theta}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{\theta^2}{n}$$

而 $\ln f(x, \theta) = -\ln \theta - \frac{x}{\theta}$

$$\left[\frac{\partial}{\partial \theta} \ln f(x, \theta) \right]^2 = \left[-\frac{1}{\theta} + \frac{x}{\theta^2} \right]^2$$

$$E \left[\frac{\partial}{\partial \theta} \ln f(X, \theta) \right]^2 = E \left[-\frac{1}{\theta} + \frac{X}{\theta^2} \right]^2 = \frac{1}{\theta^2}$$

 $\frac{1}{n E \left[\frac{\partial}{\partial \theta} \ln f(X, \theta) \right]^2} = \frac{\theta^2}{n} = D(\bar{X})$

故 \bar{X} 是达到方差下界的无偏估计量.

